

Felipe Israel dos Santos	RA.: 10729570
Igor Eduardo Dallan Do Couto	RA.: 10748144
Juliana de Oliveira Sato	RA.: 10727587
Yuri dos Santos Radziwill	RA.: 10730741

NeoLeitura: Desenvolvimento de um Sistema de Recomendação de Livros Utilizando Técnicas
de Ciência de Dados
Instituto Presbiteriano Mackenzie

São Paulo
2026

SUMÁRIO

1. INTRODUÇÃO	3
1.1 Contexto do Trabalho.....	3
1.2 Motivação	3
1.3 Justificativa	3
1.4 Objetivo	3
1.4.1 Objetivo Extensionista	3
1.4.2 Integração entre Universidade e Sociedade.....	4
1.4.3 Acesso Democrático à Leitura	4
1.4.4 Contribuição para o ODS 4 — Educação de Qualidade	4
1.4.5 Impacto Social Esperado	4
1.4.6 Objetivos Específicos	4
2. REFERENCIAL TEÓRICO.....	5
3. METODOLOGIA	6
3.1 Coleta e compreensão dos dados.....	6
3.2 Pré-processamento e limpeza dos dados	8
3.3 Análise exploratória dos dados	9
3.4 Engenharia de atributos.....	9
3.5 Modelagem do sistema de recomendação	9
3.6 Treinamento do modelo	10
3.7 Avaliação do modelo	10
3.8 Geração de recomendações	10
4. RESULTADOS.....	11
4.1 Análise exploratória	11
4.2 Métricas de avaliação:.....	12
4.3. Comparação com Baselines	12
4.4. Gráficos e visualizações.....	12
4.5. Discussão de resultados	15
5. APLICAÇÃO EM COMUNIDADE	15
6. CONCLUSÃO	16
7. REFERÊNCIA BIBLIOGRÁFICA.....	16
8. APÊNDICES.....	18

1. INTRODUÇÃO

A leitura é uma prática amplamente difundida e reconhecida por sua importância no desenvolvimento intelectual, educacional e social dos indivíduos. Além de contribuir para a ampliação do repertório cultural e do pensamento crítico, a leitura também se destaca como uma forma de lazer acessível, especialmente por meio de bibliotecas públicas e iniciativas comunitárias. No entanto, diante da grande diversidade de títulos disponíveis, muitos leitores enfrentam dificuldades para escolher obras que estejam alinhadas aos seus interesses, necessidades educacionais ou preferências pessoais, o que pode gerar desmotivação e até o abandono do hábito da leitura.

1.1 Contexto do Trabalho

Nesse contexto, o avanço das tecnologias digitais e da Ciência de Dados possibilita a criação de sistemas capazes de personalizar a experiência do usuário, auxiliando na descoberta de conteúdos relevantes em meio a grandes volumes de informação. Os sistemas de recomendação, amplamente utilizados em plataformas digitais, demonstram grande potencial para apoiar a tomada de decisão dos usuários ao sugerirem itens com base em comportamentos e preferências anteriores. Aplicar essas técnicas ao contexto da leitura representa uma oportunidade de unir tecnologia e educação, promovendo o acesso ao conhecimento de forma mais eficiente e personalizada.

O dataset utilizado neste projeto foi obtido na plataforma Kaggle, intitulado "Book Recommendation Dataset", contendo informações sobre usuários, livros e avaliações. O conjunto de dados permite a aplicação de técnicas de sistemas de recomendação, sendo adequado para análises de comportamento e personalização de recomendações.

1.2 Motivação

A motivação para a realização deste trabalho está relacionada à percepção de que, embora a leitura seja considerada uma atividade acessível, muitos indivíduos não possuem orientação adequada para a escolha de livros que atendam aos seus gostos ou objetivos de aprendizagem. Essa dificuldade é ainda mais evidente em ambientes educacionais e em projetos sociais, nos quais os perfis dos leitores são variados e as necessidades informacionais são diversas. Assim, a criação de um sistema de recomendação de livros pode atuar como uma ferramenta de apoio, facilitando a escolha de títulos e incentivando a continuidade do hábito da leitura.

1.3 Justificativa

O projeto justifica-se pela relevância social e educacional de promover o acesso à leitura por meio de soluções tecnológicas. Ao propor o desenvolvimento de um sistema de recomendação baseado nas preferências e interações dos usuários, busca-se contribuir para a democratização do acesso à informação e para o fortalecimento da educação, especialmente em contextos de bibliotecas públicas, escolas e iniciativas comunitárias. Além disso, o trabalho possibilita a aplicação prática de conceitos fundamentais de sistemas de recomendação, consolidando o aprendizado acadêmico e reforçando o caráter extensionista da proposta, ao apresentar uma solução tecnológica com potencial de aplicação real na comunidade.

1.4 Objetivo

1.4.1 Objetivo Extensionista

O projeto se caracteriza como uma ação extensionista ao integrar o conhecimento acadêmico com foco na promoção de benefícios concretos para a comunidade externa, especialmente em contextos educacionais e sociais. A proposta assume compromisso com a democratização do acesso à leitura e com a promoção da educação de qualidade.

1.4.2 Integração entre Universidade e Sociedade

O projeto estabelece uma ponte entre o ambiente acadêmico e a comunidade ao aplicar conceitos de Ciência de Dados e Sistemas de Recomendação na solução de uma demanda social concreta: a dificuldade de orientação na escolha de livros adequados ao perfil do leitor, buscando difundir o hábito da leitura.

A implementação da ferramenta em escolas públicas, bibliotecas ou projetos sociais possibilita que o conhecimento produzido seja difundido e gere impacto direto na sociedade, fortalecendo o papel social da instituição de ensino superior.

1.4.3 Acesso Democrático à Leitura

Embora a leitura seja considerada uma atividade acessível, a ausência de direcionamento adequado pode limitar seu potencial formativo. O sistema de recomendação propõe atuar como um instrumento facilitador, auxiliando leitores na descoberta de obras alinhadas aos seus interesses e necessidades educacionais.

Dessa forma, contribui para reduzir barreiras informacionais, ampliar o acesso a conteúdo relevantes e incentivar a continuidade do hábito da leitura, especialmente entre públicos que apresentam menor acompanhamento pedagógico.

1.4.4 Contribuição para o ODS 4 — Educação de Qualidade

O projeto está alinhado às metas do ODS 4, que visam assegurar educação inclusiva, equitativa e de qualidade, bem como promover oportunidades de aprendizagem ao longo da vida para todos.

A personalização das recomendações favorece:

- Maior engajamento educacional;
- Estímulo ao pensamento crítico;
- Apoio ao desenvolvimento cognitivo;
- Incentivo à aprendizagem contínua.

Ao utilizar tecnologia como ferramenta de inclusão educacional, o projeto reforça a importância da inovação aplicada ao desenvolvimento social.

1.4.5 Impacto Social Esperado

Como ação extensionista, o projeto busca gerar impactos mensuráveis na comunidade atendida, tais como:

- Aumento da frequência de leitura;
- Maior diversidade de obras exploradas pelos leitores;
- Redução da desmotivação associada à escolha inadequada de livros;
- Apoio ao desempenho acadêmico.

Assim, o sistema de recomendação não se limita a uma aplicação tecnológica, mas configura-se como instrumento de transformação educacional, promovendo o acesso ao conhecimento de forma personalizada, inclusiva e socialmente responsável.

1.4.6 Objetivos Específicos

Os objetivos específicos deste projeto estão voltados para a resolução de problemas computacionais relacionados à recomendação de livros. Para isso, serão aplicadas técnicas de Ciência de Dados que envolvem o tratamento, análise e modelagem dos dados, com o objetivo de gerar recomendações personalizadas de acordo com o perfil e as preferências dos usuários. Dessa forma, busca-se desenvolver uma solução prática que auxilie na escolha de livros e incentive o

hábito da leitura. O projeto pretende explorar abordagens como filtragem colaborativa baseada em usuários e itens, além de possíveis técnicas híbridas.

2. REFERENCIAL TEÓRICO

Segundo Freund e Corrêa (2026), observa-se um declínio global no hábito da leitura, cenário em que, pela primeira vez, o número de não leitores supera o de leitores ativos. Para mitigar esse problema, este projeto propõe o desenvolvimento de um Sistema de Recomendação. A ferramenta tem como intuito de fornecer sugestões literárias personalizadas para o público que não possui o costume de ler, buscando reinserir essas pessoas no universo literário e reduzir o tempo gasto em frente às telas.

Os sistemas de recomendação vêm sendo amplamente estudados como ferramentas de personalização da informação. Esses sistemas utilizam técnicas de análise de dados para identificar padrões e similaridades entre leitores e livros, permitindo a geração de recomendações mais relevantes e assertivas. Nesse contexto, o desenvolvimento de um sistema de recomendação, como proposto neste trabalho, busca aplicar esses conceitos de forma prática, contribuindo para facilitar a escolha de livros e promover o engajamento dos usuários com a leitura. De acordo com Adomavicius e Tuzhilin (2005), os sistemas de recomendação surgiram como uma solução para o problema de sobrecarga de informação, sendo amplamente utilizados para auxiliar usuários na identificação de itens relevantes em grandes volumes de dados. Os autores classificam esses sistemas em três principais abordagens: filtragem colaborativa, baseada em conteúdo e híbrida, além de destacarem limitações dos modelos tradicionais e a necessidade de evolução para sistemas mais inteligentes e contextualizados.

Para a continuidade do trabalho, o grupo selecionou algumas bibliotecas para a implementação do algoritmo de recomendação, entre elas o Microsoft Recommenders e o Scikit-learn. No entanto, com a base de dados escolhida, o tempo de processamento e os resultados iniciais não atenderam às expectativas. Dessa forma, optou-se pela utilização do TensorFlow, que, já nos primeiros testes, apresentou desempenho superior. A base de treinamento foi processada em aproximadamente 20 minutos, gerando recomendações significativamente mais relevantes quando comparadas às obtidas com as bibliotecas anteriormente testadas.

O TensorFlow é uma biblioteca de código aberto amplamente utilizada no campo de Machine Learning, destacando-se por sua robustez, escalabilidade e flexibilidade na construção e treinamento de modelos. A ferramenta oferece suporte a diferentes abordagens de aprendizado, além de permitir otimizações de desempenho por meio de processamento paralelo e uso de hardware acelerado, como GPUs. Dessa forma, sua adoção neste projeto possibilita a construção de modelos mais eficientes e com maior capacidade de generalização, contribuindo diretamente para a qualidade das recomendações geradas. Esta biblioteca possui uma extensão chamada Tensorflow Recommenders abreviada como TFRS, especializada em algoritmos de recomendações, possuindo especializações no treinamento e na avaliação de modelos, adicionado métricas como FactorizedTopK, que retorna a precisão de recomendações dos principais K itens para os usuários de validação.

O TensorFlow viabiliza uma das principais arquiteturas utilizada no mercado de recomendações em massa, a arquitetura Two-Tower. Este algoritmo cria duas “Torres”, uma para os usuários, processando suas similaridades, como idade e localização e uma segunda torre específica para os itens, também calculando suas similaridades, no caso de livros, calculando similaridade de autores, editoras e títulos. No final com as duas torres formadas, o modelo realiza um cálculo de produto escalar entre o vetor de usuário e vetor de item. Caso um usuário goste de determinado item o modelo ajusta os pesos das torres para os vetores se aproximarem no espaço geométrico. Com o modelo formado, a previsão de recomendações buscara na base os itens que estão mais próximo do usuário. Este algoritmo segue uma lógica de filtragem híbrida, possuindo


características de filtragem colaborativa, considerando interações entre usuário e item e ao mesmo tempo usando filtragem baseada em conteúdo já que interagem com atributos dos usuários e itens para a busca de similaridade. Este algoritmo também possui a versatilidade de ser usado em treinamentos em modelos de aprendizado supervisionado, tentando prever determinado atributo, como nota de avaliação ou também podendo ser implementado de maneira não-supervisionada fazendo buscas de feedback implícito, mapeando as similaridades dos itens, que é o caso coberto neste trabalho.

Dessa forma, o presente projeto fundamenta-se na aplicação de técnicas de sistemas de recomendação e aprendizado de máquina, integrando conceitos teóricos e práticos com o objetivo de desenvolver uma solução capaz de incentivar o hábito da leitura. Ao alinhar tecnologia e educação, busca-se não apenas facilitar a escolha de livros, mas também promover impacto social por meio do acesso personalizado ao conhecimento.

3. METODOLOGIA

O desenvolvimento do sistema de recomendação proposto neste trabalho seguiu um pipeline estruturado de Ciência de Dados, contemplando as etapas de coleta, pré-processamento, análise exploratória, modelagem, treinamento e avaliação do modelo.

A metodologia seguiu o fluxograma abaixo:



3.1 Coleta e compreensão dos dados

Foram utilizados dois conjuntos de dados para os dados de treinamento de validação, ambos disponíveis na plataforma Kaggle, sendo eles:

Book Recommendation Dataset: Disponibiliza informações de reviews e interações de leitores com livros, é composto por três arquivos principais:

Users.csv: informações demográficas dos usuários, como idade e localização, contendo os atributos;

Atributo	Descrição	tipo	Quantidade de valores nulos	Utilizado na análise
User-Id	Id do usuário	Inteiro	0	Ligação com interações
Location	Localização do usuário, considerando cidade, estado e país divididos por virgula	String	0, porém existem strings com valores parcialmente preenchidos, como por exemplo apenas País preenchido	Sim
Age	Idade do usuário	Inteiro	110762	Sim

Books.csv: características dos livros, como título, autor, editora e ano de publicação, contendo os atributos:

Atributo	Descrição	tipo	Quantidade de valores nulos	Utilizado na análise
ISBN	International standard book number, Código único do livro	String	0	Ligação com interações
Book-Author	Nome do autor do livro	String	2	Sim
Book-Title	Título do livro	String	0	Sim
Year-Of-Publication	Ano da publicação	Inteiro	0, porém com muitos valores zerados	Não, foram identificadas muitas imprecisões, outro dataset complementa esta informação.
Publisher	Editora responsável pela publicação	String	2	Sim
Image-URL-S	Imagem da capa no tamanho pequeno	String	0	Não
Image-URL-M	Imagem da capa no tamanho médio	String	0	Não
Image-URL-G	Imagem da capa no tamanho grande	String	2	Não

Ratings.csv: interações entre usuários e livros, incluindo avaliações explícitas, contendo os atributos:

Atributo	Descrição	tipo	Quantidade de valores nulos	Utilizado na análise
User-Id	Chave do usuário	Inteiro	0	Sim
ISBN	Chave do livro	String	0	Sim
Book-Rating	Nota do review, caso seja 0, representa uma interação sem nota.	Inteiro	0	Sim

Essa estrutura atende aos requisitos fundamentais de sistemas de recomendação, que envolvem usuários, itens e suas respectivas interações.

Cleaned Goodreads Books Dataset: Neste dataset é disponibilizado informações mais detalhadas de livros, contendo informações de gêneros e notas de outra plataforma, este foi utilizado para enriquecimento dos dados, neste foi utilizado os arquivos:

books_clean.parquet: Detalhes de livros, contendo os atributos:

Atributo	Descrição	tipo	Quantidade de valores nulos	Utilizado na análise
Id	Id único da plataforma	String	0	Não
Name	Nome do livro	String	0	Não
Author	Nome dos autores	String	0	Não
url	Link do livro	String	0	Não
Genres	Lista de gêneros atribuídos ao livro	Lista de String	0	Sim
Summary_clean	Sumário do livro	String	30955	Sim
Pub_year	Ano de publicação	Integer	0	Sim
Star_ratings	Ranking geral na plataforma	Numérico	0	Sim
Num_ratings	Total de notas	Integer	0	Não
Isbn_clean	International standard book number, Código único do livro	String	0	Utilizado como chave de ligação com outro dataset

3.2 Pré-processamento e limpeza dos dados

Foi realizada uma etapa de tratamento dos dados com o objetivo de garantir consistência e qualidade para o processo de modelagem. As principais transformações incluem:

- Localização de usuários: Por padrão todas as informações de localização estavam agrupadas em um único atributo. Foi realizada uma rotina para separar o campo em cidade, estado e país.
- Idade de usuários: Existiam alguns registros de usuários com idades irreais, por exemplo com idades superiores a 200 anos, para estes definiu-se uma idade máxima de 100 anos. Também existe uma quantidade considerável de usuários sem idade preenchida, para estes foi considerada a mediana de idade agrupada por país. Caso não exista país atribuído, é atribuído a mediana global.
- Ano de publicação: Existem 4621 livros com data de publicação no ano 0. Para estes foi seguido a seguinte regra para correção: Caso o título do mesmo autor esteja disponível em outra publicação de outra editora devidamente preenchido, utiliza a mesma data. Caso a primeira regra falhe, é buscado a mediana das publicações do mesmo autor, caso não seja possível aplicar nenhuma das regras anteriores, é mantido o registro com ano 0. ‘
- Títulos, autores e editoras com variações de formatação: Existem variações de uso de maiúsculas e minúsculas nos textos, possuindo o mesmo autor escrito de diferentes formas. Para o treinamento todos os campos String foram alterados para seguir o padrão letras minúsculas.
- Gêneros: Os gêneros estavam agrupados em uma lista de string. Muitos gêneros possuíam espaços na sua descrição, como “Science fiction”, neste os espaços foram substituídos por underline para serem considerados um termo único pelo TensorFlow. Após esta

transformação os gêneros passam por uma tokenização em um vetor para viabilização de sua utilização no TensorFlow.

- Sumário: O texto do sumário foi convertido para lowercase e tokenizado em um vetor para viabilização de sua utilização no TensorFlow.

Essas ações visaram reduzir ruídos e melhorar a qualidade das informações utilizadas pelo modelo.

3.3 Análise exploratória dos dados

Após o pré-processamento básico, foi realizada uma análise exploratória para identificar padrões nos dados disponíveis. Verificando dados ausentes, fora do comum ou duplicados.

Também foram criados alguns gráficos para criar visualizações dos dados como:

Histogramas

- Análise de distribuição de idade dos usuários, podendo identificar faixas etárias mais comuns

Gráficos de barra

- Totalizador das localizações mais comuns, útil para verificar tendências geográficas do dataset
- Totalizador de distribuição de notas, identificando o padrão das notas mais comuns nos reviews realizados pelos usuários.

Essas análises forneceram insumos importantes para a etapa de modelagem.

3.4 Engenharia de atributos

Nesta etapa, foram definidas e preparadas as variáveis que seriam utilizadas como entrada do modelo de recomendação.

Foram consideradas:

- Atributos de usuários: idade e localização;
- Atributos de itens: título, autor, editora e ano de publicação;
- Interações usuário-item: avaliações explícitas (ratings).

Esses atributos foram transformados em representações vetoriais, permitindo a captura de similaridades entre usuários e itens.

3.5 Modelagem do sistema de recomendação

O modelo adotado foi baseado na arquitetura Two-Tower.

Essa abordagem consiste em duas redes neurais independentes:

- Torre de usuários: responsável por aprender representações vetoriais dos usuários com base em suas características;
- Torre de itens: responsável por aprender representações vetoriais dos livros com base em seus atributos.

As saídas dessas torres são vetores em um espaço latente, sendo a similaridade entre usuário e item calculada por meio do produto escalar entre esses vetores.

Essa arquitetura caracteriza uma abordagem híbrida, pois combina aspectos de filtragem colaborativa (interações) e baseada em conteúdo (características dos itens e usuários), conforme discutido no referencial teórico.

3.6 Treinamento do modelo

O treinamento do modelo foi desenvolvido com a biblioteca TensorFlow Recommenders, uma extensão especializada do ecossistema TensorFlow que emprega arquiteturas de deep learning para otimizar a precisão das previsões. Amplamente consolidada na comunidade, essa destaca-se por sua capacidade de aprendizado de características complexas, o que favorece a generalização do modelo e facilita o processamento de cenários de cold start, permitindo recomendações mais precisas mesmo diante de dados limitados sobre novos usuários ou itens.

Para otimização do desempenho, foi aplicado um processo de ajuste de hiperparâmetros, considerando:

- Dimensão dos embeddings;
- Número de camadas e unidades;
- Taxa de aprendizado;
- Taxa de dropout.

A seleção dos melhores parâmetros foi conduzida com o da biblioteca Optuna, que utiliza o algoritmo tree-structured Parzen Estimators para fazer a busca de melhor combinação de parâmetros. Para este treinamento foi escolhido 10 rodadas de avaliações, cada rodada tentando fazer otimizações de maneira inteligente nas combinações realizadas. Esta busca foi utilizada para a melhor combinação em cada Torre, cada uma podendo ter uma combinação diferente de parâmetros, salve a dimensão de embeddings que precisam ser do mesmo tamanho de vetor para a viabilização da comunicação entre usuários e itens.

3.7 Avaliação do modelo

A avaliação do modelo foi realizada por meio de abordagem offline, utilizando a divisão dos dados em conjuntos de treinamento e teste, conforme recomendado para sistemas de recomendação.

A base foi particionada na proporção de:

- Treinamento (75% dos registros): utilizado para aprendizado do modelo;
- Teste (25% dos registros): utilizado para avaliar a capacidade de generalização.

Foram utilizadas métricas específicas para sistemas de recomendação, como FactorizedTopK: métrica utilizada na biblioteca TensorFlow Recommenders para avaliar a qualidade das recomendações, considerando entre todos os itens existentes, ao fazer uma recomendação de K itens para um usuário, quantos efetivamente fazem parte do dataset de teste.

Essas métricas permitem avaliar a efetividade do modelo na geração de recomendações relevantes para os usuários.

3.8 Geração de recomendações

Após o treinamento, o modelo é utilizado para gerar recomendações personalizadas.

Para cada usuário, o sistema calcula a similaridade entre seu vetor de características e os vetores dos livros disponíveis, retornando um ranking dos itens mais relevantes.

As recomendações finais consistem em uma lista dos livros com maior probabilidade de interesse para o usuário, contribuindo para a personalização da experiência e incentivo à leitura.


Estas recomendações também são válidas para usuários em situação de Cold Start, ou seja, usuários que ainda não tiveram interações com os itens, tentando fazer previsões baseado nas suas características demográficas.

4. RESULTADOS


4.1 Análise exploratória

Na análise exploratória podemos verificar algumas tendências dos dados disponíveis, como:


- Distribuição da idade dos usuários, evidenciando a grande predominância na faixa entre 20 e 39 anos;



- Identificação das localizações mais frequentes, podendo identificar regiões com mais suporte para treinamento;



- Análise da distribuição das avaliações, indicando predominância de avaliações positivas.



4.2. Métricas de avaliação:

Para análise de performance do modelo, foram utilizadas métricas de avaliação baseado nos resultados na predição nos dados de testes como:

- **Factorized_top_k**: métrica similar ao recall utilizado para o modelo Two-Tower, com os dados de testes, considerando todos os 96782 itens disponíveis no catálogo, ao fazer uma sugestão de K itens, quantos efetivamente estavam na lista do usuário. Utilizando o padrão da recomendação de top 10 resultados, foi obtido o valor de 0.002
- **NDCG@K**: Faz a medição de quão bem ranqueado está a recomendação, utilizando uma escala logarítmica para suavizar a queda. Utilizando o padrão em recomendações de top 10 itens, foi obtido a precisão de 0.001929
- **MRR global (Mean Reciprocal Rank)**: Métrica para avaliar sistemas de busca e recomendação, que mede o quão rapidamente o primeiro resultado é relevante para a lista retornada. Realizando uma média global do MRR, foi obtido o resultado de 0.00167

4.3. Comparação com Baselines


Para avaliar o desempenho do modelo proposto, foi realizada uma comparação com abordagens de referência. Em uma escolha aleatória entre os 96782 livros disponíveis, a precisão esperada seria de aproximadamente 0.00010332. O modelo Two-Tower apresentou desempenho cerca de 19,3 vezes superior a essa abordagem, demonstrando maior capacidade de identificar recomendações relevantes.

Também foi realizada uma comparação com um modelo KNN básico, que apresentou Recall@10 0.0050, valor superior ao modelo Two-Tower. No entanto, apesar do desempenho superior na escolha no dataset de validação, o KNN apresenta limitações em cenários de cold start, especialmente para novos usuários ou novos itens no catálogo, pois depende fortemente de interações previamente registradas e muitas vezes apelando em recomendações de itens extremamente populares, sem considerar os valores reais das features.


Dessa forma, o modelo Two-Tower mostrou-se mais adequado para o contexto do projeto, uma vez que combina informações de usuários, itens e interações, permitindo recomendações mais flexíveis e personalizadas.

4.4. Gráficos e visualizações

Após cada treinamento, foram analisados os gráficos de aprendizado gerados a partir do histórico das épocas de treinamento. Essa análise permitiu acompanhar a evolução da função de perda e da acurácia, além de verificar possíveis indícios de overfitting.




Também foi realizada uma análise visual da tendência de acerto considerando diferentes quantidades de itens recomendados, com o objetivo de observar se havia crescimento consistente no desempenho conforme o valor de K aumentava. Também foi criada uma segunda série comparando a probabilidade de acerto baseado em recomendações aleatórias.




Para validar a distribuição das recomendações entre diferentes perfis de usuários, foram criados mapas de calor comparando características como região e faixa etária com os gêneros mais recomendados. Essa análise permitiu observar diferenças na distribuição das recomendações de acordo com os segmentos avaliados.


O primeiro mapa de calor estuda a distribuição de recomendações de gêneros literários em diferentes países. Podemos notar que alguns países como Espanha tem uma grande preferência pelos clássicos da literatura, enquanto o gênero “mistério” tende ser mais recomendado para o Estados Unidos e também podendo notar que alguns gêneros possuem uma distribuição mais homogênea independente do país de origem do usuário.



O segundo mapa realiza a análise para faixas etárias, podemos ver tendências nas recomendações, como por exemplo, o gênero “Young Adult” tem grande tendência em ser recomendado mais para usuários na faixa de 11 a 30 anos, enquanto categorias como “Mystery” tem mais tendência a ser recomendado para usuários na faixa dos 41 e 70 anos.



E por fim foi realizado uma análise cruzada nas duas informações, comparando a faixa etária de 30 a 39 anos através de diferentes localidades, validando diferentes distribuições de gêneros dentro da mesma faixa etária.



Outra análise realizada foi a simulação de recomendações para usuários existentes no sistema, ou seja, que já possuem um mínimo de interações e validar a qualidade das recomendações.

O usuário escolhido para o teste tem 33 anos e é morador do Canada. Em suas interações com os registros existentes possui um gosto em literatura inglesa, humor, mistério e

autobiografias. O modelo apresentou recomendações seguindo estas características, nas top 10 recomendações indicou 3 livros de humor, 3 livros de mistério e uma autobiografia. Outro detalhe foi que 50% das recomendações foram de autores ingleses, altamente reforçado por suas interações anteriores. Uma das recomendações foi um livro extremamente técnico que aparenta ser uma sugestão fora da curva e provavelmente com pouco valor, provavelmente sendo por conta de algum ruído no embedding dos sumários.

Outro teste na mesma linha foi o teste com usuários de cold start, testando a recomendação com usuários de diferentes países e faixas etárias, sem nenhuma interação com os itens dos catálogos. Um destes testes foi para um cidadão da Espanha de 47 anos. O modelo apresentou uma variação de clássicos da literatura e livros populares dos anos 90, sendo recomendações condizentes com o usuário europeu dessa faixa etária.

4.5. Discussão de resultados

Entre os principais pontos positivos do modelo Two-Tower, destaca-se sua capacidade de combinar diferentes tipos de informação, como atributos dos usuários, características dos livros e interações registradas na base. Essa abordagem permite maior flexibilidade em relação a modelos mais simples, além de apresentar potencial para lidar com cenários de cold start, nos quais há poucos dados históricos sobre determinados usuários ou itens.

Outro ponto positivo é a possibilidade de gerar recomendações personalizadas por meio da representação vetorial de usuários e livros em um espaço latente, permitindo o cálculo de similaridade entre diferentes perfis e itens.

Por outro lado, o modelo também apresenta limitações. O desempenho depende diretamente da qualidade e completude dos dados utilizados, e a presença de registros ausentes, inconsistentes ou pouco representativos pode afetar a precisão das recomendações. Além disso, por se tratar de uma abordagem baseada em redes neurais, o modelo exige maior custo computacional e maior complexidade de implementação quando comparado a técnicas mais simples, como modelos baseados em popularidade ou KNN.

Embora as métricas obtidas não tenham apresentado valores elevados, o sistema demonstrou capacidade de generalizar informações a partir das características dos usuários e dos livros. As análises indicaram que o modelo conseguiu identificar tendências distintas de recomendação para usuários de diferentes faixas etárias e regiões geográficas. Além disso, quando comparado à escolha aleatória de itens, o modelo apresentou desempenho superior, reforçando sua capacidade de gerar recomendações mais direcionadas.

Uma das principais dificuldades observadas durante o desenvolvimento foi a preparação dos dados. Foi necessário remover registros com baixo suporte, especialmente usuários e livros com poucas interações, o que reduziu significativamente a base útil disponível para treinamento. Esse fator pode ter impactado diretamente o desempenho das métricas, evidenciando a importância da qualidade e da densidade dos dados em sistemas de recomendação.

5. APLICAÇÃO EM COMUNIDADE

Como parte do caráter extensionista do projeto, o NeoLeitura foi pensado como uma ferramenta de apoio à promoção do hábito da leitura em contextos educacionais e sociais, como escolas, bibliotecas, projetos comunitários e iniciativas de incentivo à leitura.

A proposta busca auxiliar leitores na escolha de livros mais alinhados aos seus interesses, reduzindo a dificuldade inicial de seleção de obras e incentivando a continuidade da prática leitora. Dessa forma, o sistema de recomendação atua como um recurso tecnológico voltado à democratização do acesso à leitura e ao fortalecimento da educação.

Para demonstrar sua aplicabilidade, o projeto foi apresentado em vídeo, evidenciando seu funcionamento, seus objetivos sociais e sua contribuição para a comunidade. Essa apresentação também reforça a relação entre universidade e sociedade, ao mostrar como conhecimentos de Ciência de Dados podem ser aplicados na solução de problemas reais.

6. CONCLUSÃO

O trabalho teve como objetivo desenvolver um sistema de recomendação de livros utilizando técnicas de Ciência de Dados e aprendizado de máquina, buscando incentivar o hábito da leitura por meio de recomendações personalizadas. A partir da utilização de datasets públicos contendo informações de usuários, livros e avaliações, foi possível aplicar etapas completas de um pipeline de Ciência de Dados, incluindo coleta, tratamento, análise exploratória, engenharia de atributos, modelagem, treinamento e avaliação do modelo.

Os resultados obtidos demonstraram que a arquitetura Two-Tower implementada com TensorFlow Recommenders apresentou desempenho satisfatório na identificação de padrões de similaridade entre usuários e livros, conseguindo gerar recomendações coerentes mesmo em cenários de cold start. Além disso, as análises realizadas evidenciaram que fatores como faixa etária e localização influenciam diretamente os padrões de recomendação, permitindo maior personalização das sugestões geradas pelo sistema.

Embora as métricas de avaliação não tenham alcançado valores elevados, o modelo demonstrou capacidade de generalização superior à escolha aleatória e apresentou vantagens em relação a abordagens mais simples, especialmente na utilização de atributos demográficos e características dos livros. O projeto também reforçou a importância do pré-processamento e da qualidade dos dados para o desempenho de sistemas de recomendação.

Do ponto de vista social e extensionista, o trabalho contribui para a democratização do acesso à leitura, propondo uma ferramenta capaz de auxiliar usuários na descoberta de obras alinhadas aos seus interesses e necessidades educacionais. Dessa forma, o sistema possui potencial de aplicação em bibliotecas, escolas e projetos sociais, promovendo inclusão educacional e incentivo ao aprendizado contínuo.

Como trabalhos futuros, pretende-se ampliar a base de dados utilizada, incorporar novas informações textuais dos livros, como descrições completas e resenhas, além de explorar modelos mais avançados de recomendação baseados em transformers e processamento de linguagem natural. Também é prevista a implementação de uma interface web interativa para disponibilização prática do sistema aos usuários finais, bem como a realização de avaliações online com usuários reais para medir satisfação e relevância das recomendações.

7. REFERÊNCIA BIBLIOGRÁFICA

ZIEGLER, Cai-Nicolas. **Book Recommendation Dataset**. Kaggle, 2024. Disponível em: <https://www.kaggle.com/datasets/arashnic/book-recommendation-dataset>. Acesso em: 23 fev. 2026.

ODAGUIRI, Henrique Kenzo; ARAÚJO, Elisângela Ferreira; STRINGHINI, Denise; OLIVEIRA, Tiago de. **Sistemas de recomendação de leitura e sua implementação: revisão sistemática da literatura nacional**. RENOTE, Porto Alegre, v. 23, n. 1, p. 181–192, 2025. DOI: 10.22456/1679-1916.149226.

Disponível em: <https://seer.ufrgs.br/index.php/renote/article/view/149226>. Acesso em: 23 mar. 2026.

ABREU FERNANDES DE QUEIROZ, I. L.; DA SILVA, J. F. A. .; DE CASTRO, A. F. **SIRLiB – Sistema de Indicação e Recomendação de Livros em Bibliotecas: Um sistema de recomendação de livros para fomentar a leitura**. Revista Gestão do Conhecimento e Tecnologia da Informação, v. 9, n. Edição Especial, p. 41-49, 5 abr. 2025.

NOGUEIRA, Daniel Silva. **Bookify: explorando o uso de sistemas de recomendação**. 2023. Trabalho de Conclusão de Curso (Tecnólogo em Análise e Desenvolvimento de Sistemas) – Instituto Federal de Educação, Ciência e Tecnologia da Paraíba, Cajazeiras, 2023. Disponível em: <https://repositorio.ifpb.edu.br/handle/177683/3246>. Acesso em: 23 mar. 2026.

FREUND, Alexander; CORRÊA, Fábio. **Leitura tem queda dramática e preocupante pelo mundo**. G1, 6 fev. 2026. Disponível em: <https://g1.globo.com/educacao/noticia/2026/02/06/leitura-tem-queda-dramatica-e-preocupante-pelo-mundo.ghtml>. Acesso em: 24 mar. 2026.

ABADI, Martín et al. **TensorFlow: Large-scale machine learning on heterogeneous systems**. 2015. Disponível em: <https://arxiv.org/abs/1603.04467>. Acesso em: 27 mar. 2026.

TENSORFLOW. **TensorFlow Recommenders**. [S. l.]: TensorFlow, [202-?]. Disponível em: <https://www.tensorflow.org/recommenders?hl=pt-br>. Acesso em: 27 mar. 2026.

WORTZ, Jeremy; TOTTEN, Jordan. **Scaling deep retrieval with TensorFlow Recommenders and Vertex AI Matching Engine**. Google Cloud Blog, 19 abr. 2023. Disponível em <https://cloud.google.com/blog/products/ai-machine-learning/scaling-deep-retrieval-tensorflow-two-towers-architecture>. Acesso em 28 mar. 2026

YI, Xinyang; YANG, Ji; HONG, Lichan; CHENG, Derek Zhiyuan; HELDT, Lukasz; KUMTHEKAR, Aditee; ZHAO, Zhe; WEI, Li; CHI, Ed H. **Sampling-Bias-Corrected Neural Modeling for Large Corpus Item Recommendations**. In: *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19)*. Copenhagen, Denmark: Association for Computing Machinery, 2019. p. 23-32. Disponível em: <https://storage.googleapis.com/gweb-research2023-media/pubtools/5716.pdf>. Acesso em 28 mar. 2026

ADOMAVICIUS, Gediminas; TUZHILIN, Alexander. **Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions**. IEEE

Transactions on Knowledge and Data Engineering, New York, v. 17, n. 6, p. 734-749, June 2005.
Disponível em: <https://ieeexplore.ieee.org/document/1423975>. Acesso em: 27 mar. 2026.

MLTF. *Hyperparameter Optimization (HPO)*. Disponível em:
<https://docs.mltf.vu/tutorials/HPO.html> Acesso em: 19 abr. 2026.

EVIDENTLY AI. ***Mean Reciprocal Rank (MRR) explained.*** [S. l.], 9 jan. 2025. Disponível em:
<https://www.evidentlyai.com/ranking-metrics/mean-reciprocal-rank-mrr> Acesso em: 09 maio 2026.

8. APÊNDICES

A) Link do vídeo no YouTube

<https://youtu.be/aOfNosTNng8>

B) Link para o GitHub

<https://github.com/YuriRadzi/NeoLeitura>

C) Link para o Dataset

Book Recommendation Dataset:

<https://www.kaggle.com/datasets/arashnic/book-recommendation-dataset>

Cleaned Goodreads Books Dataset:

<https://www.kaggle.com/datasets/ishanrealstate/goodreads-cleaned-dataset>